

입력 이미지 배경 비율에 따른 위장 객체 분류 성능 분석

장소현[°]

박현희^{°°}

명지대학교 인공지능융합학과^{°°°}

Analysis of Camouflaged Object Classification Performance According to Input Image Background Ratio

Sohyeon Jang[°]

Hyunhee Park^{°°}

Dept. Applied Artificial Intelligence, Myongji University^{°°°}

jangso6593[°], hhpark^{°°}@mju.ac.kr

요 약

본 논문에서는 위장 객체 분류 성능에 입력 이미지의 배경 비율이 미치는 영향을 실험적으로 분석한다. 경계 상자 면적을 기준으로 배경 비율 $R_{bg} \in \{0, 10, 25, 50, 90, 100\}$ (%)을 정의하고 COD10K 데이터셋을 12 개 클래스로 재구성하여 ResNet-50 과 Swin-Tiny 기반 분류 모델로 실험을 수행하였다. 실험 결과 배경 비율이 증가할수록 분류 성능이 향상되는 경향을 확인하였으며 클래스별로 최적 배경 비율이 달라질 수 있음을 확인하였다. 이는 배경 문맥 정보가 위장 객체 분류의 중요한 단서로 작용함을 시사한다.

1. 서론

위장 객체 분류는 주변 환경과 시각적으로 유사한 객체의 클래스를 판별하는 작업으로, 배경과의 경계가 불분명하여 인식이 어렵다. 기존 연구는 탐지 및 분할에 집중되어 왔으며[1] 입력 이미지의 어떤 시각적 요소가 분류 성능에 영향을 미치는지에 대한 분석은 미흡한 실정이다.

이에 본 논문에서는 입력 이미지의 배경 비율이 위장 객체 분류 성능에 미치는 영향을 실험적으로 분석한다. 경계 상자 면적을 기준으로 배경 비율 R_{bg} 를 정의하고 6 가지 조건으로 입력 이미지를 구성하여 ResNet-50 과 Swin-Tiny 기반 분류 모델로 실험을 수행한다. 본 연구는 위장 객체 분류에서 배경 문맥 정보의 역할을 규명하고 향후 분류 모델 고도화를 위한 기초 근거를 제공하는 것을 목적으로 한다.

2. 방법론

배경 비율 R_{bg} 는 입력 이미지에서 객체의 경계 상자 면적을 기준으로 배경이 차지하는 비율로 정의된다. 본 실험에서는 $R_{bg} \in \{0, 10, 25, 50, 90, 100\}$ (%)의 6 가지 조건에 대해 실험을 수행하며 그림 1 은 R_{bg} 조건별 입력 이미지 예시를 나타낸다.




그림 1. 배경 비율별 입력 이미지 예시

2.1 배경 비율 기반 영역 추출

$R_{bg} = 0\%$ 의 경우 경계 상자 영역을 추출한 후 이진 마스크와의 곱 연산을 통해 배경을 완전히 제거하였다. $R_{bg} = 100\%$ 의 경우 원본 이미지를 그대로 사용하였다. $R_{bg} \in \{10, 25, 50, 90\}$ (%)의 경우 경계 상자의 높이(H)와 너비(W)로부터 객체 면적 $A_{obj} = W \times H$ 를 구하고 목표 면적 A_{target} 을 다음과 같이 계산한다.

$$A_{target} = \frac{A_{obj}}{1 - R_{bg}} \quad (1)$$

확장 배율 s 와 새로운 너비(W_{new}) 및 높이(H_{new})는 다음과 같이 정의된다.

$$s = \sqrt{\frac{1}{1 - R_{bg}}} \quad (2)$$

$$W_{new} = W \cdot s, \quad H_{new} = H \cdot s \quad (3)$$

목표 추출 영역은 경계 상자의 중심점 (C_x, C_y)를 기준으로 생성된다.

$$x_{min} = C_x - \frac{W_{new}}{2}, x_{max} = C_x + \frac{W_{new}}{2} \quad (4)$$

이후 추출 영역이 원본 이미지 경계를 벗어나는 경우 다음과 같이 이동(Shift)한다.

$$\text{if } x_{min} < 0: x_{max} -= x_{min}, x_{min} = 0 \quad (5)$$

$$\text{if } x_{max} > W: x_{min} -= (x_{max} - W), x_{max} = W$$

이동 이후에도 경계를 벗어나면 원본 이미지 경계에 고정한다(Clamp). x 축 처리는 다음과 같으며 y 축에도 동일하게 적용된다.

$$\begin{aligned} x_{min} &= \text{clamp}(x_{min}, 0, W), \\ x_{max} &= \text{clamp}(x_{max}, 0, W) \end{aligned} \quad (6)$$




그림 2. 배경 비율 기반 영역 추출 과정

2.2 분류 모델 및 학습 설정




그림 3. 분류 모델 처리 흐름

인코더로 ResNet-50[2]과 Swin-Tiny[3]를 사용하였으며 두 모델은 ImageNet 사전 학습된 가중치로 초기화하였다. 분류 헤드는 인코더의 출력 특징 벡터를 입력으로 받아 클래스를 예측하는 다층 퍼셉트론(MLP)으로 구성하였다. 손실 함수는 교차 엔트로피($\mathcal{L}_{CE}$)를 사용하였다.

3. 실험 결과

Train bg	ResNet-50	Swin-Tiny
0	0.372	0.458
10	0.534	0.605
25	0.583	0.639
50	0.604	0.667
90	0.678	0.722
100	0.672	0.735

표 1. 학습 배경 비율 별 분류 성능 (macro F1-score)

Train bg (%)	pipefish	katydid	Butterfly	F1-avg
0	0.093	0.410	0.233	0.372
10	0.661	0.519	0.464	0.534
25	0.766	0.543	0.541	0.583
50	0.742	0.500	0.583	0.604
90	0.776	0.531	0.617	0.678
100	0.792	0.500	0.571	0.672

표 2. ResNet-50 대표 클래스별 분류 성능 (macro F1-score)

Train bg (%)	pipefish	katydid	Butterfly	F1-avg
0	0.137	0.434	0.305	0.458
10	0.773	0.489	0.515	0.605
25	0.819	0.518	0.535	0.639
50	0.835	0.546	0.556	0.667
90	0.861	0.580	0.642	0.722
100	0.898	0.581	0.658	0.735

표 3. Swin-Tiny 대표 클래스별 분류 성능 (macro F1-score)

COD10K[4] 데이터셋을 12 개 클래스로 재구성하여 실험하였으며, 분류 성능 평가 지표로 macro F1-score를 사용하였다. 표 1 은 배경 비율에 따른 전체 성능을 표 2~3 은 대표 클래스별 성능을 나타낸다.

두 모델 모두 배경 비율이 증가할수록 전체적으로 성능이 향상되는 경향을 보였다. ResNet-50 은

$R_{bg} = 90\%$ 에서 최고 성능(0.678) 기록한 반면 Swin-Tiny 는 $R_{bg} = 100\%$ 에서 최고 성능(0.735)을 기록하였다. 이는 Swin-Tiny 가 ResNet-50 에 비해 넓은 문맥 정보를 더 효과적으로 활용하였기 때문으로 판단된다. 표 2 에서 pipefish 는 배경 비율에 비례하여 성능이 향상했고 katydid 는 낮은 배경 비율에서도 빠르게 성능이 수렴하였으며 butterfly 는 90% 비율에서 성능이 정점에 달한 후 하락하는 양상을 보였다. 이를 통해 클래스 별로 최적의 배경 환경이 달라질 수 있음을 확인하였다.

4. 결론

본 논문에서는 객체와 배경의 비율이 위장 객체 분류 성능에 미치는 영향에 대해 ResNet-50 과 Swin-Tiny 기반 분류 모델로 실험을 수행하였다. 실험 결과 적절한 배경 비율을 포함하는 조건에서 성능이 향상되는 경향을 확인했으며 이는 배경 문맥 정보가 위장 객체 분류의 중요한 단서로 작용함을 시사한다.

향후 클래스 특성에 따른 최적 배경 비율 탐색 및 이를 활용한 분류 모델 고도화를 목표로 한다.

ACKNOWLEDGMENT

이 논문은 산업통상자원부 및 산업기술기획평가원(KEIT)과 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. 2022R1A2C2005705, 분산 머신러닝 기반 지능형 플라잉 기지국을 위한 AI-MAC 프로토콜, No. RS-2024-00469138, 국산 AI 반도체 기반 비전 인식기술 소프트웨어개발도구 개발)

5. 참고 문헌

- [1] C. Lei, et al., "Towards real zero-shot camouflaged object segmentation without camouflaged annotations," IEEE Trans. Pattern Anal. Mach. Intell., vol. 47, no. 12, pp. 11990-12004, Dec. 2025.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), pp. 770-778, 2016.
- [3] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, "Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows," in Proc. IEEE Int. Conf. Comput. Vis. (ICCV), pp. 10012-10022, 2021.
- [4] D.-P. Fan, et al., "Camouflaged object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), pp. 2774-2784, Seattle, WA, USA, June 2020.