

# 특징 혼동도와 시선 편향도 기반 위장 객체 학습 편향 분석

장소현, 박현희\*  
명지대학교

{jangso6593, hhpark\*}@mju.ac.kr

## Learning Bias Analysis in Camouflaged Object Detection via Feature Confusion and Attention Bias

Sohyeon Jang, Hyunhee Park\*  
Myongji University

요 약

본 논문은 위장 객체 학습에서 발생하는 학습 편향을 정량화하기 위해 특징 혼동도( $S_{sim}$ )와 시선 편향도( $S_{bias}$ ) 두 지표를 제안한다. 위장 객체 탐지 모델은 약 85%의 이미지에서 주의가 배경에 집중되는 학습 편향을 보인다. 학습 편향이 발생한 이미지의 평균 IoU는 그렇지 않은 이미지 대비 약 54% 낮아 학습 편향이 모델의 일반화 성능을 저해함이 정량적으로 확인된다.

### I. 서 론

위장 객체 탐지(camouflaged object detection, COD)는 배경과 유사하게 위장된 객체를 분할하는 과제로 객체의 색상·질감 등 고유한 특징이 약하다는 어려움이 있다[1]. 이로 인해 모델은 객체의 특징보다 배경 패턴 등 거짓 상관관계에 의존하기 쉬우며 이러한 학습 편향은 일반화 성능 저하로 이어질 수 있다[2]. 그러나 기존 COD 연구는 탐지 정확도 향상에 집중되어 있어 위장 객체 학습 시 발생하는 편향과 성능의 관계에 대한 정량적 분석은 충분히 다루어지지 않았다.

본 논문은 모델 내부에서 나타나는 객체-배경 표상 혼동성과 시선 편향을 정량화하는 두 지표를 제안한다. 특징 혼동도  $S_{sim}$ 는 인코더 특징 맵에서 객체 영역과 배경 영역의 평균 특징 벡터 간 코사인 유사도로 정의되며 시선 편향도  $S_{bias}$ 는 Grad-CAM 활성화 맵에서 배경 영역과 객체 영역의 활성화 밀도 비율로 정의된다. 본 논문은 다음 두 분석을 수행한다. (i)  $S_{sim}$ 과  $S_{bias}$ 를 두 축으로 COD10K와 DUTS의 이미지 분포를 비교하여 위장 객체가 일반 객체보다 높은 특징 혼동과 시선 편향을 보임을 입증한다. (ii) 위장 객체 학습 데이터의  $S_{sim} \cdot S_{bias}$  중앙값을 기준선으로 한 사분면에서 검증 데이터의 IoU 격차를 통해 시선 편향이 일반화 성능 저하와 직접 연결됨을 입증한다.

### II. 제안 기법




그림 1. 이미지별  $S_{sim}, S_{bias}$  측정 파이프라인

본 절은 학습이 완료된 모델로부터 입력 이미지 마다 두 지표  $S_{sim}, S_{bias}$ 를 산출하는 방법을 기술한다.

#### 2.1 특징 혼동도

특징 혼동도는 학습이 완료된 모델의 특징 공간에서 객체 영역과 배경 영역의 평균 특징 벡터 간 유사도로 정의된다. 두 평균 벡터의 유사도가 높을수록 모델이 객체와 배경을 특징 공간에서 분리하지 못한 것으로 해석한다. 이를 위해 인코더 마지막 계층에서 추출한 특징 맵을 사용한다. 입력 이미지의 특징 맵  $F$ 를 정답 마스크  $G$ 로 객체 영역과 배경 영역에 분리한 뒤 각 영역에 속한 특징 벡터의 평균을 산출하여 객체 평균 벡터  $v_{obj}$ 와 배경 평균 벡터  $v_{bg}$ 를 얻는다.

$$v_{obj} = \frac{\sum(F \odot G)}{\sum G} \quad (1)$$

$$v_{bg} = \frac{\sum(F \odot (1 - G))}{\sum(1 - G)} \quad (2)$$

특징 혼동도  $S_{sim}$ 는 두 평균 벡터 간 코사인 유사도로 정의된다.

$$S_{sim} = \cos(v_{obj}, v_{bg}) \quad (3)$$

산출된  $S_{sim}$  값은  $[0, 1]$  범위에 분포하며 이상치의 영향을 줄이기 위해 데이터의 5/95 백분위수를 기준으로 한 P5-95 min-max 정규화를 적용한다.

#### 2.2 시선 편향도

시선 편향도는 모델의 주의가 객체보다 배경에 치우친 정도로 정의된다. 주의가 배경에 치우칠수록 모델이 객체의 특징 대신 배경의 거짓 상관관계에 의존한 것으로 해석한다. 학습이 완료된 모델에 Grad-CAM [3]을 적용한 활성화 맵  $CAM$ 을 정답 마스크  $G$ 로 분리하여 객체 영역과 배경 영역의 평균 활성화 밀도  $d_{obj}, d_{bg}$ 를 산출한다.

$$d_{obj} = \frac{\sum CAM_{obj} \odot G_{obj}}{\sum G_{obj}} \quad (4)$$

$$d_{bg} = \frac{\sum CAM_{bg} \odot (1 - G_{obj})}{\sum G_{bg}} \quad (5)$$

시선 편향도  $S_{bias}$  는 배경과 객체의 활성화 밀도 비로 정의된다.

$$S_{bias} = \frac{d_{bg}}{d_{obj} + \epsilon} \quad (6)$$

여기서  $\epsilon$ 은 0 으로 나누어지는 것을 방지하기 위한 작은 상수 값이다.  $S_{bias}$  는  $[0, \infty)$  범위를 가지므로 데이터의 95 백분위수(P95)로 나눈 뒤 1로 클리핑하는 robust 정규화를 적용하여  $[0, 1]$  범위로 변환한다.

### III. 분석 결과

#### 3.1 위장 객체의 학습 편향 유도

본 절은 위장 객체 학습이 학습 편향을 유도하는지 검증하기 위해 동일 구조의 두 모델을 비교 분석한다. 두 모델은 ResNet-50 백본의 동일 구조와 동일 학습 이미지 수를 사용한다. 위장 모델은 COD10K, NC4K, CHAMELEON, CAMO 를 통합한 위장 데이터로 돌출 객체 모델은 DUTS 로 학습한다.




그림 2. 두 데이터의  $S_{sim}, S_{bias}$  산점도

그림 2에서는 두 데이터를 통합한 분포를 기준으로  $S_{sim}$  은 P5~95,  $S_{bias}$  는 P95 정규화를 적용하였다. 통합 분포의 중앙값( $S_{sim} = 0.27, S_{bias} = 0.40$ )을 기준으로 사분면을 정의한다. 사분면 라벨의 첫 글자는  $S_{sim}$ , 두 번째 글자는  $S_{bias}$ 가 중앙값보다 high (H)인지 low (L)인지를 나타낸다. HH 는 객체-배경 특징이 유사하고 주의도 배경에 향한 경우, HL 은 특징이 유사하나 주의는 객체에 향한 경우, LH 는 특징이 분리되었음에도 주의가 배경에 향한 경우, LL 은 특징이 분리되고 주의도 객체에 향한 경우이다.

표 1. 사분면별 이미지 분포

| 사분면 \ 데이터셋 | COD 데이터셋 | DUTS  |
|------------|----------|-------|
| HH         | 5,745    | 1,026 |
| LH         | 3,182    | 560   |
| LL         | 671      | 6,100 |
| HL         | 915      | 2,827 |

표 1 과 같이 두 모델은 사분면별 이미지 분포에서 명확한 차이를 보이며 이는 위장 객체 학습이 학습 편향을 유도함을 보여준다. 시선 편향이 높은 LH·HH 영역에 위장 데이터는 8,927 장, 돌출 데이터는 1,586 장이 분포하여 위장 객체에서 시선 편향이 더 자주 발생함이 정량적으로 확인된다. 특히 LH 는 객체와 배경을 특징 공간에서 분리할 수 있음에도 주의가 배경에 쏠린 경우로 모델의 분리 능력이 아닌 학습 편향이 원인인 사례로 해석된다.

#### 3.2 시선 편향과 일반화 성능 저해

COD10K 학습 데이터로 훈련한 위장 모델을 평가 데이터에 적용하여 IoU 를 산출한다. 학습 데이터의  $S_{sim}, S_{bias}$  중앙값( $S_{sim} = 0.94, S_{bias} = 0.32$ )을 기준으로 평가 데이터의 각 이미지를 사분면에 분류한다.

표 2. 사분면별 평균 IoU 및 실패율(QFR)

| 사분면 | 데이터 수 | 평균 IoU | QFR(%) |
|-----|-------|--------|--------|
| HH  | 279   | 0.1447 | 95.70  |
| LH  | 382   | 0.1571 | 90.31  |
| LL  | 581   | 0.2695 | 80.21  |
| HL  | 784   | 0.3752 | 69.77  |

표 2 와 같이 시선 편향이 낮은 그룹(LL, HL)의 평균 IoU 는 0.330 인 반면 시선 편향이 높은 그룹(LH, HH)의 평균 IoU 는 0.152 로 약 54.0% 낮은 값을 보인다. 특히 LH 는 객체와 배경을 특징 공간에서 분리할 수 있음에도 IoU 0.157 로 HH(0.145)와 유사한 낮은 수치를 기록하여 시선 편향이 특징 분리와 무관하게 성능 저하를 유발함을 보여준다. 분석을 정량화하기 위해 사분면별 실패율(quadrant failure rate, QFR)을  $QFR(q) = N(q \cap Failure) / N(q)$ 로 정의하며 Failure 는 IoU < 0.5 인 이미지이다. 표 2 에서 시선 편향이 높은 LH(90.31%)와 HH(95.70%)의 QFR 이 시선 편향이 낮은 LL(80.21%)과 HL(69.77%)보다 일관되게 높게 나타나 위장 객체 학습이 유도한 시선 편향이 모델의 일반화 성능을 저해함을 정량적으로 입증한다.

### IV. 결론

본 논문은 위장 객체 학습에서 발생하는 편향을 정량화하는 특징 혼동도( $S_{sim}$ )와 시선 편향도( $S_{bias}$ )를 제안한다. 두 지표를 통해 위장 객체 학습이 시선 편향을 더 자주 유도하며 편향이 모델의 일반화 성능을 저해함을 정량적으로 입증하였다. 본 분석은 위장 객체의 시각적 특성이 거짓 상관관계 학습을 유발함을 보여주며 학습 편향 완화 연구의 정량적 토대로 활용될 수 있다.

### ACKNOWLEDGMENT

이 논문은 산업통상자원부 및 산업기술기획평가원(KEIT)과 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. 2022R1A2C2005705, 분산머신러닝 기반 지능형 플라잉 기지국을 위한 AI-MAC 프로토콜, No. RS-2024-00469138, 국산 AI 반도체 기반 비전인식기술 소프트웨어개발도구 개발)

### 참고 문헌

- [1] D.-P. Fan, G.-P. Ji, M.-M. Cheng, and L. Shao, "Concealed Object Detection," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 10, pp. 6024-6042, Oct. 2022, doi: 10.1109/TPAMI.2021.3085766.
- [2] C. He, R. Zhang, F. Xiao, D. Zhang, Z. Cao, and S. Farsiu, "Refining Context-Entangled Content Segmentation via Curriculum Selection and Anti-Curriculum Promotion," arXiv preprint arXiv:2602.01183, Feb. 2026.
- [3] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," in Proc. IEEE Int. Conf. Computer Vision (ICCV), Oct. 2017, pp. 618-626, doi: 10.1109/ICCV.2017.74.